

ĐỀ CƯƠNG CHI TIẾT DỰ ÁN CÔNG NGHỆ THÔNG TIN

Tên đề tài: Xây dựng mô hình lai Matrix Factorization và Deep Neural Network để gợi ý sản phẩm

Thời gian thực hiện: 4 tháng (16 tuần)

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1. Lý do chọn đề tài

Hệ thống gợi ý (Recommender System) đóng vai trò quan trọng trong thương mại điện tử và bán lẻ hiện đại, giúp cá nhân hóa trải nghiệm người dùng và gia tăng doanh thu. Trong các phương pháp lọc cộng tác (Collaborative Filtering), Matrix Factorization (MF) nắm bắt tốt các tương tác tuyến tính ẩn giữa người dùng và sản phẩm nhưng bị hạn chế trong việc học các quan hệ phi tuyến phức tạp. Deep Neural Network (DNN) bổ sung khả năng học biểu diễn phi tuyến mạnh mẽ. Việc xây dựng một mô hình lai kết hợp cả hai hướng tiếp cận (theo tinh thần Neural Collaborative Filtering) cho phép tận dụng đồng thời ưu điểm của cả MF lẫn DNN, hứa hẹn cải thiện chất lượng gợi ý so với từng phương pháp đơn lẻ.

1.2. Mục tiêu nghiên cứu

- Xây dựng mô hình lai kết hợp Generalized Matrix Factorization (GMF) và Multi-Layer Perceptron (MLP) để dự đoán mức độ ưa thích/khả năng tương tác giữa người dùng và sản phẩm.
- Cài đặt, huấn luyện và tinh chỉnh mô hình trên tập dữ liệu tương tác người dùng - sản phẩm.
- Đánh giá và so sánh hiệu quả mô hình lai với các mô hình thành phần (MF thuần, DNN thuần) và các phương pháp lọc cộng tác truyền thống.
- Xây dựng ứng dụng/API demo minh họa chức năng gợi ý Top-K sản phẩm.

1.3. Đối tượng và phạm vi nghiên cứu

- Đối tượng nghiên cứu:** dữ liệu tương tác người dùng - sản phẩm dạng implicit feedback (số lượt mua, số lượt xem, số lần đặt hàng).
- Phạm vi:** giải quyết bài toán gợi ý Top-K sản phẩm (Top-K recommendation); không đi sâu vào các bài toán gợi ý theo ngữ cảnh thời gian thực phức tạp (session-based/sequential recommendation) — có thể đề cập như hướng phát triển.

1.4. Phương pháp nghiên cứu

- Nghiên cứu lý thuyết: các mô hình lọc cộng tác, Matrix Factorization, mạng nơ-ron nhân tạo, các kiến trúc gợi ý lai hiện có.
- Nghiên cứu thực nghiệm: cài đặt mô hình, huấn luyện, đánh giá so sánh trên tập dữ liệu thực nghiệm.

1.5. Ý nghĩa khoa học và thực tiễn

- **Khoa học:** thực nghiệm và phân tích hiệu quả của việc kết hợp hai nhánh học biểu diễn tuyến tính (MF) và phi tuyến (DNN) trong cùng một kiến trúc cho bài toán gợi ý.
- **Thực tiễn:** hệ thống gợi ý xây dựng được có thể tích hợp vào các nền tảng thương mại điện tử/bán lẻ nhằm nâng cao trải nghiệm cá nhân hóa và hiệu quả kinh doanh.

1.6. Bố cục báo cáo

Báo cáo gồm 6 chương: (1) Tổng quan, (2) Cơ sở lý thuyết, (3) Phân tích và thiết kế hệ thống, (4) Cài đặt và thực nghiệm, (5) Kết quả và đánh giá, (6) Kết luận và hướng phát triển.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Hệ thống gợi ý (Recommender Systems)

- Loại cộng tác dựa trên người dùng (User-based Collaborative Filtering) và dựa trên sản phẩm (Item-based Collaborative Filtering).
- Loại dựa trên nội dung (Content-based Filtering).
- Hệ thống gợi ý lai (Hybrid Recommendation).

2.2. Matrix Factorization

- Nguyên lý phân rã ma trận tương tác User-Item thành hai ma trận đặc trưng ẩn (latent factor matrices).
- Các kỹ thuật: SVD (Singular Value Decomposition), ALS (Alternating Least Squares), BPR (Bayesian Personalized Ranking) cho dữ liệu implicit feedback.

2.3. Deep Neural Network cho bài toán gợi ý sản phẩm

- Multi-Layer Perceptron học các tương tác phi tuyến giữa embedding của người dùng và sản phẩm.
- Các kiến trúc liên quan trong lĩnh vực: Wide & Deep Learning, DeepFM, Neural Collaborative Filtering (NeuMF).

2.4. Kiến trúc mô hình lai đề xuất

- **Nhánh GMF (Generalized Matrix Factorization):** mô phỏng cơ chế MF truyền thống bằng phép nhân element-wise giữa vector embedding người dùng và vector embedding sản phẩm.
- **Nhánh MLP:** nối (concatenate) embedding người dùng và sản phẩm, đưa qua nhiều lớp fully-connected để học các tương tác phi tuyến bậc cao.
- **Kết hợp hai nhánh:** nối đầu ra của GMF và MLP, đưa qua lớp fully-connected cuối cùng để dự đoán điểm số tương tác (theo kiến trúc NeuMF).

2.5. Các nghiên cứu liên quan

Tổng hợp các công trình về hệ thống gợi ý lai (hybrid recommendation), phân tích ưu điểm/hạn chế của từng hướng tiếp cận, từ đó xác định điểm mới/khoảng trống mà đề tài hướng tới giải quyết.

CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1. Phát biểu bài toán

- **Đầu vào:** ma trận tương tác User-Item với implicit feedback (giá trị nhị phân 0/1 hoặc số lượng tương tác đã chuẩn hóa).
- **Đầu ra:** điểm số dự đoán khả năng tương tác (dạng xác suất), dùng để xếp hạng và chọn ra Top-K sản phẩm gợi ý cho mỗi người dùng.

3.2. Kiến trúc mô hình chi tiết

- Lớp Embedding riêng biệt cho nhánh GMF và nhánh MLP (không dùng chung trọng số, nhằm tăng khả năng biểu diễn của mô hình).
- Số lớp ẩn của MLP, hàm kích hoạt (ReLU), các kỹ thuật chống overfitting (Dropout, Batch Normalization).
- Hàm mất mát: Binary Cross-Entropy (kết hợp kỹ thuật negative sampling cho dữ liệu implicit feedback) hoặc Mean Squared Error (nếu sử dụng dữ liệu rating tường minh).

3.3. Chiến lược huấn luyện

- Áp dụng kỹ thuật negative sampling để sinh các cặp User-Item chưa từng tương tác làm nhãn âm.
- Tiền huấn luyện (pretrain) riêng lẻ hai nhánh GMF và MLP, sau đó khởi tạo trọng số ban đầu cho mô hình kết hợp (NeuMF) và tinh chỉnh (fine-tune) toàn bộ mạng — theo chiến lược huấn luyện được đề xuất trong các nghiên cứu nền tảng về kiến trúc lai này.

3.4. Thiết kế dữ liệu và pipeline xử lý

Sơ đồ luồng xử lý: dữ liệu giao dịch/tương tác thô → làm sạch, chuẩn hóa → xây dựng ma trận tương tác User-Item → sinh negative samples → chia tập huấn luyện/kiểm tra (áp dụng chiến lược leave-one-out cho việc đánh giá Top-K) → huấn luyện mô hình.

3.5. Ưu điểm và nhược điểm của mô hình đề xuất

Ưu điểm:

- Kết hợp đồng thời ưu điểm của Matrix Factorization (nhắm bắt hiệu quả tương tác tuyến tính, chi phí tính toán thấp) và Deep Neural Network (học được các tương tác phi tuyến bậc cao mà MF thuần không biểu diễn được).
- Thường cho độ chính xác gợi ý (HR@K, NDCG@K) tốt hơn so với từng mô hình thành phần dùng riêng lẻ.

- Kiến trúc linh hoạt, dễ mở rộng: có thể bổ sung thêm nhánh đặc trưng nội dung (content-based) hoặc đặc trưng ngữ cảnh mà không cần thay đổi toàn bộ mô hình.
- Vector embedding học được mang thông tin ngữ nghĩa hữu ích, có thể tái sử dụng cho các mục đích phân tích khác (phân cụm sản phẩm, phân khúc khách hàng...).
- Chiến lược tiền huấn luyện (pretrain) riêng từng nhánh trước khi kết hợp giúp mô hình hội tụ ổn định hơn so với huấn luyện toàn bộ từ đầu.

Nhược điểm có thể khắc phục — kèm hướng giải quyết toàn diện:

Nhược điểm	Nguyên nhân	Hướng giải quyết
Vấn đề cold-start với user/item mới ít dữ liệu tương tác	Mô hình collaborative filtering phụ thuộc vào lịch sử tương tác	Bổ sung đặc trưng nội dung sản phẩm/hồ sơ người dùng (hybrid content-based); dùng giá trị embedding trung bình theo nhóm/danh mục cho item mới; áp dụng kỹ thuật few-shot/meta-learning nếu cần
Cần khối lượng dữ liệu tương tác đủ lớn để huấn luyện nhánh DNN hiệu quả	MLP có nhiều tham số, dễ học kém nếu dữ liệu ít	Tăng cường dữ liệu qua negative sampling hợp lý; pretrain trên tập dữ liệu tổng hợp lớn hơn rồi fine-tune trên tập mục tiêu; giảm độ sâu MLP nếu dữ liệu hạn chế
Nguy cơ overfitting do số lượng tham số lớn	Nhiều lớp fully-connected, embedding chiều cao	Áp dụng Dropout, Batch Normalization, L2 regularization, early stopping dựa trên tập validation
Chi phí huấn luyện/tính toán cao hơn so với MF thuần	Lan truyền ngược qua nhiều lớp mạng	Tối ưu số chiều embedding và số lớp MLP ở mức hợp lý; tận dụng GPU; áp dụng kỹ thuật nén mô hình (pruning/quantization) khi triển khai thực tế
Kết quả nhạy cảm với lựa chọn siêu tham số (embedding dim, số lớp, tỉ lệ negative sampling)	Không gian siêu tham số lớn	Áp dụng Grid Search/Random Search hoặc Bayesian Optimization kết hợp tập validation riêng biệt
Khả năng diễn giải kết quả thấp hơn so với MF truyền thống	Cấu trúc phi tuyến nhiều lớp	Phân tích/trực quan hóa cụm embedding sản phẩm-người dùng tương tự; hiển thị "sản phẩm tương tự đã tương tác trước đó" làm căn cứ giải thích gợi ý

Nhược điểm mang tính bất khả kháng (tính chất vốn có của mô hình, không thể loại bỏ hoàn toàn):

- Về bản chất, mọi mô hình collaborative filtering (kể cả khi đã bổ sung content-based) đều cần một lượng tương tác lịch sử tối thiểu để suy luận sở thích; với trường hợp **cold-start tuyệt đối** (user/item hoàn toàn mới, chưa từng có bất kỳ tương tác hay đặc trưng mô tả nào), không một mô hình nào — kể cả mô hình lai — có thể đưa ra dự đoán chính xác mà không dựa vào giả định/suy diễn gián tiếp; đây là giới hạn lý thuyết cố hữu của mọi hệ gợi ý dựa trên dữ liệu tương tác, không riêng gì mô hình MF+DNN.
- Là một kiến trúc mạng nơ-ron sâu phi tuyến, NeuMF vốn dĩ mang tính chất hộp đen (black-box); việc diễn giải chính xác tuyệt đối cơ chế ra quyết định ở cấp độ từng tham số/trọng số là điều không thể đạt được triệt để (khác với mô hình tuyến tính đơn giản như MF thuần) — đây là đặc tính cố hữu của mọi mô hình học sâu, không phải hạn chế riêng có thể khắc phục bằng kỹ thuật cài đặt.

CHƯƠNG 4: CÀI ĐẶT VÀ THỰC NGHIỆM

4.1. Chuẩn bị dữ liệu

Nguồn dữ liệu tham khảo đề xuất: bộ dữ liệu DataCo Supply Chain Dataset (Kaggle) — bộ dữ liệu giao dịch bán lẻ/thương mại điện tử với hàng chục nghìn đơn hàng và hơn 50 thuộc tính, bao gồm các trường hữu ích cho đề tài:

- `Customer Id` — đóng vai trò "user" trong ma trận tương tác.
- `Product Name`, `Product Card Id`, `Category Name`, `Department Name` — đóng vai trò "item" và đặc trưng nội dung phụ trợ (side information) cho sản phẩm, hỗ trợ xử lý cold-start.
- `Order Item Quantity`, `Order Date`, `Order Id` — dùng để xây dựng tín hiệu implicit feedback (số lần/số lượng khách hàng đã đặt một sản phẩm).
- `Sales`, `Order Item Total` — có thể dùng làm trọng số bổ sung cho mức độ quan tâm (implicit rating có trọng số) thay vì chỉ đếm nhị phân 0/1.

Quy trình xử lý: (1) tổng hợp theo từng cặp `Customer Id` - `Product Name` để tính số lần tương tác, hình thành ma trận User-Item ở dạng implicit feedback; (2) áp dụng ngưỡng lọc để loại bỏ khách hàng/sản phẩm có quá ít tương tác (giảm nhiễu); (3) sinh negative samples từ các cặp chưa từng xuất hiện; (4) chia tập huấn luyện/kiểm tra theo chiến lược leave-one-out (giữ lại tương tác gần nhất của mỗi khách hàng để đánh giá Top-K). Các trường `Category Name`, `Department Name` có thể tận dụng thêm cho hướng phát triển hybrid content-based ở Chương 6.

4.2. Cài đặt mô hình GMF độc lập

Cài đặt và huấn luyện mô hình GMF làm baseline, đánh giá sơ bộ.

4.3. Cài đặt mô hình MLP độc lập

Cài đặt và huấn luyện mô hình MLP làm baseline, đánh giá sơ bộ.

4.4. Cài đặt mô hình lai NeuMF (kết hợp GMF và MLP)

Kết hợp trọng số đã tiền huấn luyện từ hai nhánh, tinh chỉnh (fine-tune) toàn bộ mô hình kết hợp.

4.5. Tinh chỉnh siêu tham số

Số chiều embedding, số lớp và số nơ-ron của MLP, tốc độ học (learning rate), tỉ lệ negative sampling.

4.6. Xây dựng API/ứng dụng demo

Xây dựng API trả về danh sách Top-K sản phẩm gợi ý cho một người dùng cụ thể; xây dựng giao diện demo trực quan (web đơn giản hoặc Streamlit).

CHƯƠNG 5: KẾT QUẢ VÀ ĐÁNH GIÁ

5.1. Chỉ số đánh giá

- Hit Ratio@K (HR@K).
- Normalized Discounted Cumulative Gain@K (NDCG@K).
- Precision@K, Recall@K.

5.2. So sánh các mô hình

So sánh định lượng giữa mô hình MF thuần (GMF), DNN thuần (MLP) và mô hình lai (NeuMF); trình bày bảng số liệu và biểu đồ.

5.3. Nghiên cứu đối chứng (Ablation study)

Phân tích ảnh hưởng của số chiều embedding, số lớp MLP, tỉ lệ negative sampling đến chất lượng gợi ý.

5.4. Kiểm thử tình huống cold-start

Đánh giá khả năng gợi ý cho người dùng/sản phẩm mới, ít dữ liệu tương tác.

5.5. Demo giao diện gợi ý sản phẩm

Trình bày kết quả demo: nhập một người dùng, hệ thống trả về danh sách Top-K sản phẩm gợi ý kèm điểm số.

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Tổng kết đóng góp chính của đề tài: xây dựng thành công mô hình lai MF+DNN, chứng minh mô hình kết hợp cho kết quả tốt hơn so với từng mô hình thành phần riêng lẻ; xây dựng được API/demo gợi ý sản phẩm hoạt động ổn định.

6.2. Hạn chế

Chưa xử lý được yếu tố ngữ cảnh thời gian thực (session-based); dữ liệu thử nghiệm có thể chưa đủ lớn để đánh giá đầy đủ khả năng mở rộng của mô hình.

6.3. Hướng phát triển

- Bổ sung yếu tố thời gian/chuỗi hành vi người dùng (sequential/session-based recommendation).
- Kết hợp thêm đặc trưng nội dung sản phẩm (content-based features) để tăng khả năng xử lý cold-start.
- Mở rộng triển khai thực tế trên hệ thống có lượng người dùng/sản phẩm lớn hơn.

TÀI LIỆU THAM KHẢO GỢI Ý

1. Koren, Y., Bell, R., & Volinsky, C. — *Matrix Factorization Techniques for Recommender Systems*, IEEE Computer, 2009.
2. He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T.-S. — *Neural Collaborative Filtering*, WWW 2017.
3. Cheng, H.-T. et al. — *Wide & Deep Learning for Recommender Systems*, DLRS 2016.
4. Guo, H. et al. — *DeepFM: A Factorization-Machine based Neural Network for CTR Prediction*, IJCAI 2017.
5. Rendle, S., Freudenthaler, C., Gantner, Z., & Schmidt-Thieme, L. — *BPR: Bayesian Personalized Ranking from Implicit Feedback*, UAI 2009.
6. Ricci, F., Rokach, L., & Shapira, B. — *Recommender Systems Handbook* (chương tổng quan về Collaborative Filtering).

(Sinh viên bổ sung, cập nhật thêm tài liệu tham khảo theo yêu cầu định dạng trích dẫn của trường/khoa.)

KẾ HOẠCH THỰC HIỆN 16 TUẦN

Tuần	Nội dung công việc
1-2	Khảo sát tài liệu liên quan (Collaborative Filtering, MF, NeuMF, Wide&Deep, DeepFM), xác định phạm vi, chọn bộ dữ liệu, hoàn thiện đề cương chi tiết
3-4	Thu thập, làm sạch dữ liệu; xây dựng ma trận tương tác User-Item; thiết kế pipeline negative sampling và chia tập train/test
5-6	Cài đặt và huấn luyện mô hình GMF độc lập; đánh giá sơ bộ
7-8	Cài đặt và huấn luyện mô hình MLP độc lập; đánh giá sơ bộ
9-10	Cài đặt mô hình lai NeuMF (kết hợp GMF + MLP), tiền huấn luyện và fine-tune
11	Tinh chỉnh siêu tham số (số chiều embedding, số lớp MLP, tỉ lệ negative sampling)
12	So sánh định lượng các mô hình (GMF, MLP, NeuMF) qua HR@K, NDCG@K
13	Thực hiện ablation study và kiểm thử tình huống cold-start
14	Xây dựng API và giao diện demo gợi ý sản phẩm
15	Viết báo cáo dự án (các chương kết quả, hoàn thiện nội dung)
16	Rà soát, chỉnh sửa, chuẩn bị slide và báo cáo/bảo vệ dự án